


Machine Learning

Chapter 4 지도학습 (타이타닉 데이터 실습)



문제 정의 및 요구사항 분석




- 이전까지 학습한 내용을 적용할 수 있다.
- 다양한 특성 공학의 방법들을 활용할 수 있다.
- 탐색적 데이터 분석(EDA)을 수행할 수 있다.
- 머신러닝을 이용하여 타이타닉 데이터의 생존/
 사망자를 예측할 수 있다.





타이타닉 데이터를 이용한 머신러닝 학습 실습



데이터 수집



타이타닉 데이터 구조


- 훈련 데이터 891개, 테스트 데이터 418개
- 테스트 데이터에는 survived 컬럼이 없음
- 10개 특성으로 구성

feature	의미	설명	타입
Survivied	생존여부	target 라벨 (0 : 생존, 1 : 사망)	integer
Pclass	티켓의 클래스	1 = 1등석, 2 = 2등석, 3 = 3등석	integer
Sex	성별	male, female로 구분	string
Age	나이	0-80세	integer
SibSp	함께 탑승한 형제와 배우자의 수		integer
Parch	함께 탑승한 부모, 아이의 수		integer
Ticket	티켓 번호	alphabat + integer	integer
Fare	탑승료		float
Cabin	객실 번호	alphabat + integer	string
Embarked	탑승 항구	C = Cherbourg, Q = Queenstown, S = Southampton	string

데이터 수집



타이타닉 구조





결측치(null data) 확인 – info() 함수

train 데이터

<class 'pandas.core.frame.DataFrame'> RangeIndex: 891 entries, 0 to 890 Data columns (total 12 columns): Passengerld 891 non-null int64 Survived 891 non-null int64 Pclass 891 non-null int64 891 non-null object Name Sex 891 non-null object Age 714 non-null float64 SibSp 891 non-null int64 Parch 891 non-null int64 Ticket 891 non-null object 891 non-null float64 Fare Cabin 204 non-null object Embarked 889 non-null object dtypes: float64(2), int64(5), object(5)

memory usage: 83.6+ KB

test 데이터

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 418 entries, 0 to 417
Data columns (total 11 columns):
Passengerld
               418 non-null int64
               418 non-null int64
Polass
Name
               418 non-null object
               418 non-null object
Sex
               332 non-null float64
Age
SibSp
               418 non-null int64
Parch
               418 non-null int64
Ticket
               418 non-null object
Fare
               417 non-null float64
Cabin
               91 non-null object
Embarked
               418 non-null object
dtypes: float64(2), int64(4), object(5)
memory usage: 36.0+ KB
```



결측치(null data) 확인

train.isnull().sum()

Survived	0
Pclass	0
Name	0
Sex	0
Age	177
SibSp	0
Parch	0
Ticket	0
Fare	0
Cabin	687
Embarked	2
dtype: i	nt64



이상치(outlier) / 간단한 통계 확인 – describe()

	Passengerld	Survived	Pclass	Age	SibSp	Parch	Fare
count	891.000000	891.000000	891.000000	714.000000	891.000000	891.000000	891.000000
mean	446.000000	0.383838	2.308642	29.699118	0.523008	0.381594	32.204208
std	257.353842	0.486592	0.836071	14.526497	1.102743	0.806057	49.693429
min	1.000000	0.000000	1.000000	0.420000	0.000000	0.000000	0.000000
25%	223.500000	0.000000	2.000000	20.125000	0.000000	0.000000	7.910400
50%	446.000000	0.000000	3.000000	28.000000	0.000000	0.000000	14.454200
75%	668.500000	1.000000	3.000000	38.000000	1.000000	0.000000	31.000000
max	891.000000	1.000000	3.000000	80.000000	8.000000	6.000000	512.329200



결측치 채우기 - Age

Pclass와 Sex 컬럼에 해당하는 Age의 평균을 계산

pt1

		Age
Pclass	Sex	
1	female	34.611765
	male	41.281386
2	female	28.722973
	male	30.740707
3	female	21.750000
	male	26.507589



apply() 함수: 정의된 함수를 전체 데이터에 적용

컬럼명 = train.apply(함수명, axis=1).astype('int64')



결측치 채우기 - Age

```
def fill_age(row):
    if np.isnan(row['Age']):
        return pt1.loc[row['Pclass'], row['Sex']]
    else:
        return row['Age']
```

train['Age'] = train.apply(fill_age, axis=1).astype('int64')



test 데이터의 Age 컬럼의 결측치를 피벗 테이블의 해당 값으로 채우고 결과 확인하기



결측치 채우기 - Embarked

결측치가 적으므로 가장 많은 수를 차지하는 클래스로 치환

train 데이터

```
S 644
C 168
Q 77
Name: Embarked, dtype: int64
```

train['Embarked'] = train['Embarked'].fillna('S')



결측치 채우기 - Fare

train 데이터의 Pclass와 Sex 컬럼에 해당하는 Fare의 평균을 계산

		Fare
Pclass	Sex	
1	female	106.125798
	male	67.226127
2	female	21.970121
	male	19.741782
3	female	16.118810
	male	12.661633



결측치 채우기 - Fare

test 데이터의 결측치가 있는 Pclass와 Sex 컬럼에 해당하는 Fare 값을 채우기

test[test['Fare'].isnull()]

	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
Passengerld										
1044	3	Storey, Mr. Thomas	male	60	0	0	3701	NaN	NaN	S

test['Fare'] = test['Fare'].fillna(12.661633)



결측치 채우기 - Cabin

train['Cabin'].unique()

```
array([nan] 'C85', 'C123', 'E46', 'G6', 'C103', 'D56', 'A6',
       <mark>'C23</mark> C25 C27', 'B78', 'D33', 'B30', 'C52', 'B28', 'C83'. 'F33'.
      'F G73'. 'E31'. 'A5'. 'D10 D12'. 'D26'. 'C110'. 'B58 B60'. 'E101'.
       'F E69', 'D47', 'B86', 'F2', 'C2', 'E33', 'B19', 'A7', 'C49', 'F4',
       'A32'. 'B4'. 'B80'. 'A31'. 'D36'. 'D15', 'C93', 'C78', 'D35',
      'C87', 'B77', 'E67', 'B94', 'C125', 'C99', 'C118', 'D7', 'A19',
       'B49', 'D', 'C22 C26', 'C106', 'C65', 'E36', 'C54',
      'B57 B59 B63 B66', 'C7', 'E34', 'C32', 'B18', 'C124', 'C91', 'E40',
      'T', 'C128', 'D37', 'B35', 'E50', 'C82', 'B96 B98', 'E10', 'E44',
       'A34', 'C104', 'C111', 'C92', 'E38', 'D21', 'E12', 'E63', 'A14',
       'B37', 'C30', 'D20', 'B79', 'E25', 'D46', 'B73', 'C95', 'B38',
       'B39', 'B22', 'C86', 'C70', 'A16', 'C101', 'C68', 'A10', 'E68',
       'B41'. 'A20'. 'D19', 'D50', 'D9', 'A23', 'B50', 'A26', 'D48',
    Cabin 번호는 첫 글자는 영문자로 나머지는 숫자로 구성
       "E121", "D11", "E77", "F38", "B3", "D6", "B82 B84", "D17", "A36",
       'B102', 'B69', 'E49', 'C47', 'D28', 'E17', 'A24', 'C50', 'B42',
       'C148'l. dtvpe=obiect)
```



결측치 채우기 – Cabin

(1) nan인 값을 영문자 M으로 채움

```
train['Deck'] = train['Cabin'].fillna('M')
```

(2) 첫 영문자만 잘라내어 Deck 컬럼에 저장

```
train['Deck'] = train['Deck'].str[0]
```


(3) Cabin 컬럼 삭제

train.drop('Cabin', inplace=True, axis=1)



Deck (객실번호) 시각화

객실번호에 따른 생존자/사망자 수 분석





groupby() 함수: 컬럼을 그룹핑하는 기능

deck=train[['Deck','Survived','Name']]
.groupby(['Deck','Survived']).count()


sns.countplot(data=train, x='Deck',
hue='Survived')

		Name
Deck	Survived	
Α	0	8
	1	7
В	0	12
	1	35
С	0	24
	1	35
D	0	8
	1	25
E	0	8
	1	24
F	0	5
	1	8
G	0	2
	1	2
М	0	481
	1	206
Т	0	1



Pclass (등급) 시각화


등급에 따른 생존자/사망자 수 분석





Deck와 Pclass 시각화


Deck에 따른 Pclass 수 분석






Sex, Embarked 시각화

Sex와 Embarked에 따른 생존자/사망자 수 분석








Violin plot: 3개의 변수를 시각화하는 도구


- KDE 플롯과 박스 플롯을 합쳐놓은 것
- 가운데 흰색점 : 중앙값
- 가운데 두꺼운 검정색 선
 - 흰점 아래쪽 끝이 25%,
 - 위쪽 끝이 75%
- 가운데 얇은 검정색 선 : 신뢰 구간





Sex, Age에 따른 생존자/사망자 수 시각화

plt.figure(figsize=(15,5))
sns.violinplot(data=train, x='Sex', y='Age',
hue='Survived', split=True)





Age를 binning하여 범주형 데이터로 변경

- Age_cat 컬럼에 저장

Age < 10	0
10 <= Age < 20	1
20 <= Age < 30	2
30 <= Age < 40	3
40 <= Age < 50	4
50 <= Age < 60	5
60 <= Age < 70	6
70 <= Age	7




Fare를 정규분포로 변환

plt.figure(figsize=(8,8))

g = sns.distplot(train['Fare'], c olor='b', label='{:.2f}'.format(t rain['Fare'].skew()))

g.legend()






Fare를 정규분포로 변환

train['Fare'] = np.log(train['Fare'] + 1) test['Fare'] = np.log(test['Fare'] + 1)

plt.figure(figsize=(8,8))
g = sns.distplot(train['Fare'],
color='b', label='{:.2f}'.format(
train['Fare'].skew()))
g.legend()






Parch(부모자식), Sibsp(형제자매) 통합

train['Family_Size'] = train['Parch'] + train['SibSp'] + 1 test['Family_Size'] = test['Parch'] + test['SibSp'] + 1

sns.countplot(data=train, x='Family_Size',
hue='Survived')





Parch(부모자식), Sibsp(형제자매) 통합

- 가족사이즈가 1이면 Alone, 2~4면 Small, 5이상이면 Large

```
bins = [0,1,4,11]
labels = ['Alone','Small','Large']
```

train['Family_Group'] = pd.cut(train['Family_Size'], bi ns=bins, labels=labels)

test['Family_Group'] = pd.cut(test['Family_Size'],
bins=bins, labels=labels)



Name 시각화

- Name 값에 공통적으로 , 호칭. 이 공통적으로 포함

```
Passenger I d
                                 Braund, Mr. Owen Harris
       Cumings, Mrs. John Bradley (Florence Briggs Th...
                                  Heikkinen, Miss. Laina
            Futrelle, Mrs. Jacques Heath (Lily May Peel)
                                Allen, Mr. William Henry
887
                                   Montvila, Rev. Juozas
888
                            Graham, Miss. Margaret Edith
                Johnston, Miss. Catherine Helen "Carrie"
889
890
                                   Behr, Mr. Karl Howell
891
                                     Dooley, Mr. Patrick
Name: Name, Length: 891, dtype: object
```



Name 시각화

- 호칭만 추출하여 Initial 컬럼을 생성하여 저장

```
def split_title(row):
    return row.split(',')[1].split('.')[0].strip()
```

```
train['Initial'] = train['Name'].apply(split_title)
test['Initial'] = test['Name'].apply(split_title)
```



Initial 통합

- Master, Mr, Mrs, Miss, Other



Initial 통합

train['Initial'].unique()

```
array(['Mr', 'Mrs', 'Miss', 'Master', 'Other'], dtype=object)
```



Ticket 컬럼 삭제 / 필요 없는 칼럼 삭제

```
train.drop('Ticket',axis=1,inplace=True)
train.drop('Cabin', axis=1, inplace=True)
train_drop('Family_Size',axis=1,inplace=True)
train.drop('Age', axis=1, inplace=True)
train.drop('Parch',axis=1,inplace=True)
train.drop('SibSp',axis=1,inplace=True)
train.drop('Name',axis=1,inplace=True)
```



전처리가 완료된 최종 데이터 셋

1 train.head())								
	Survived	Pclass	Sex	Fare	Embarked	Deck	Age_cat	Family_Group	Initial
Passengerld									
1	0	3	male	1.981001	S	М	2	Small	Mr
2	1	1	female	4.266662	С	С	3	Small	Mrs
3	1	3	female	2.070022	S	М	2	Alone	Miss
4	1	1	female	3.972177	S	С	3	Small	Mrs
5	0	3	male	2.085672	S	М	3	Alone	Mr



상관관계 분석 (Label Encoding 수행)

Sex	
male	0
female	1

Embarked				
С	0			
Q	1			
S	2			

Family Group				
Alone	0			
Small	1			
Large	2			

Deck		
А	0	
В	1	
С	2	
D	თ	
E	4	
F	5	
G	6	
M	7	
Т	8	

Initial		
Master	0	
Miss	1	
Mr	2	
Mrs	3	
Other	4	




상관관계 분석 (Label Encoding 수행)

	Survived	Pclass	Sex	Fare	Embarked	Deck	Age_cat	Family_Group	Initial
Passengerld									
1	0	3	0	1.981001	2	7	2	1	2
2	1	1	1	4.266662	0	2	3	1	3
3	1	3	1	2.070022	2	7	2	0	1
4	1	1	1	3.972177	2	2	3	1	3
5	0	3	0	2.085672	2	7	3	0	2



상관관계 분석

plt.figure(figsize=(14,12)) sns.heatmap(train.corr(), annot=True)





One-hot Encoding



훈련데이터와 테스트데이터 구조를 같도록 처리

<class 'nandas core frame DataFrame'>

<pre><class 'pandas.core.frame.dataframe'=""></class></pre>					
Int64Index: 891 entries, 1 to 891					
Data	columns (total				
#	Column	Non	-Null Count	Dtype	
0	Sex		non-null	int64	
1	Fare		non-null	float64	
2	Pclass_1	891	non-null	uint8	
3	Pclass_2	891	non-null	uint8	
4	Pclass_3	891	non-null	uint8	
5	Embarked_0	891	non-null	uint8	
6	Embarked_1	891	non-null	uint8	
7	Embarked_2	891	non-null	uint8	
8	Deck_O	891	non-null	uint8	
9	Deck_1	891	non-null	uint8	
10	Deck_2	891	non-null	uint8	
11	Deck_3	891	non-null	uint8	
12	Deck_4	891	non-null	uint8	
13	Deck_5	891	non-null	uint8	
14	Deck_6	891	non-null	uint8	
15	Neck 7	891		uint8	
16	Deck_8	891	non-null		
17	Age_cat_U		non-null	uint8	
18	Age_cat_1	891		uint8	
19	Age_cat_2	891		uint8	
20	Age_cat_3	891	non-nul l		
21	Age_cat_4	891	non-null		
22	Age_cat_5	891		uint8	
23	Age_cat_6	891	non-null	uint8	
24	Age_cat_7	891	non-null	uint8	
25	Family_Group_O			uint8	
26				uint8	
	Family_Group_1		non-null		
27	Family_Group_2	891	non-null	uint8	
27 28	Family_Group_2 Initial_0	891 891	non-null	uint8 uint8	
27 28 29	Family_Group_2 Initial_0 Initial_1	891 891 891	non-null non-null non-null	uint8 uint8 uint8	
27 28 29 30	Family_Group_2 Initial_0 Initial_1 Initial_2	891 891 891 891	non-null non-null non-null non-null	uint8 uint8 uint8 uint8	
27 28 29 30 31	Family_Group_2 Initial_0 Initial_1 Initial_2 Initial_3	891 891 891 891	non-null non-null non-null non-null non-null	uint8 uint8 uint8 uint8 uint8	
27 28 29 30 31 32	Family_Group_2 Initial_0 Initial_1 Initial_2 Initial_3 Initial_4	891 891 891 891 891	non-null non-null non-null non-null non-null	uint8 uint8 uint8 uint8 uint8 uint8	
27 28 29 30 31 32 dtyp	Family_Group_2 Initial_0 Initial_1 Initial_2 Initial_3 Initial_4 es: float64(1),	891 891 891 891 891 int6	non-null non-null non-null non-null non-null	uint8 uint8 uint8 uint8 uint8 uint8	
27 28 29 30 31 32 dtyp	Family_Group_2 Initial_0 Initial_1 Initial_2 Initial_3 Initial_4	891 891 891 891 891 int6	non-null non-null non-null non-null non-null	uint8 uint8 uint8 uint8 uint8 uint8	

<class 'pandas.core.frame.dataframe'=""> Int64 ndex: 418 entries, 892 to 1309</class>				
Data columns (total 32 columns):				
#			Dtivne	
		Non-Null Count		
0	Sex Fare Pclass_1 Pclass_2 Pclass_3	418 non-null	int64	
1	Fare	418 non-null	float64	
2	Pclass_1	418 non-null	uint8	
3	Pclass_2	418 non-null	uint8	
4	Pclass_3	418 non-null	uint8	
5	Emparked_U	418 non-null	uint8	
6	Embarked_1	418 non-null	uint8	
7	Embarked_2	418 non-null	uint8	
8	Deck_O	418 non-null	uint8	
9	Embarked_1 Embarked_2 Deck_0 Deck_1 Deck_2 Deck_3 Deck_4 Deck_5 Deck_6 Deck_7 Age_cat_0 Age_cat_1 Age_cat_2 Age_cat_3 Age_cat_4	418 non-null	uint8	
10	Deck_2	418 non-null	uint8	
11	Deck_3	418 non-null	uint8	
12	Deck_4	418 non-null	uint8	
13	Deck_5	418 non-null	uint8	
14	Deck_6	418 non-null	uint8	
15	Deck_7	418 non-null	uint8	
16	Age_cat_0	418 non-null	uint8	
17	Age_cat_1	418 non-null	uint8	
18	Age_cat_2	418 non-null	uint8	
19	Age_cat_3	418 non-null	uint8	
20	Age_cat_4 Age_cat_5	418 non-null	uint8	
21	Age_cat_5	418 non-null	uint8	
	Age_cat_6			
23		418 non-null	uint8	
24	Family_Group_O	418 non-null	uint8	
25	Family_Group_1	418 non-null	uint8	
26	Family_Group_2	418 non-null	uint8	
27	Initial_O Initial_1 Initial_2 Initial_3 Initial_4	418 non-null	uint8	
28	Initial_1	418 non-null	uint8	
29	Initial_2	418 non-null	uint8	
30	Initial_3	418 non-null	uint8	
31	Initial_4	418 non-null	uint8	
dtypes: float64(1), int64(1), uint8(30)				
memory usage: 22.0 KB				

 $X_{\text{test['Deck_8']}} = 0$



KNeighborsClassifier

DecisionTreeClassifier

모델 선택 및 학습



교차검증을 이용하여 모델을 평가해보자